소상공인 폐업 예측 모델

상권, 업종, 매출, 소비자 정보를 통해
폐업 가능성을 예측하고 리스크를 진단하여 폐업을 예방하다

팀명: DM
팀원: 이정수, 양원선

목차

01 분석 배경 및 필요성
- 프로젝트 개요 — 3 page

02 데이터 분석
- 데이터 분석 로드맵 — 3 page
- 데이터 전처리
- 파생변수 생성
- 변수선택
- 최종데이터셋

03 모델링
- 모델링 실행 과정 — 14 page
- 모델링 분석 결과
- k - means

04 아이디어 제안
- 인사이트 도출 — 19 page
- 활용방안

프로젝트 개요

소상공인이란?

생계형 창업 중심의 **소규모 자금과 소점포**로 창업을 시작하여 영세한 조건으로 사업을 영위하는 개인 또는 법인

소상공인 폐업 위기와 데이터 기반 예측의 필요성

자영업자의 심각한 폐업률 상황

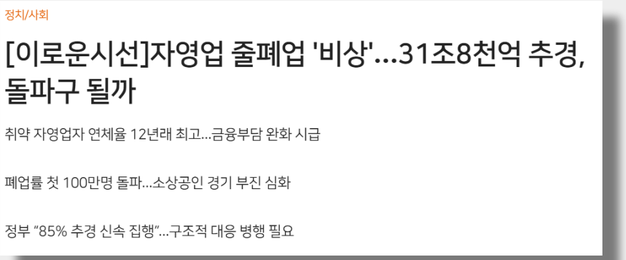
정치/사회

[이로운시선]자영업 줄폐업 '비상'...31조8천억 추경, 돌파구 될까

취약 자영업자 연체율 12년래 최고...금융부담 완화 시급

폐업률 첫 100만명 돌파...소상공인 경기 부진 심화

정부 "85% 추경 신속 집행"...구조적 대응 병행 필요

- 폐업률 100만명 돌파
- 자영업자 수가 전년 동월 대비 2만2000명(-0.4%) 감소됨
- **자영업 생태계의 불안정성**이 심화되고 있음

데이터 기반 상권분석의 수요

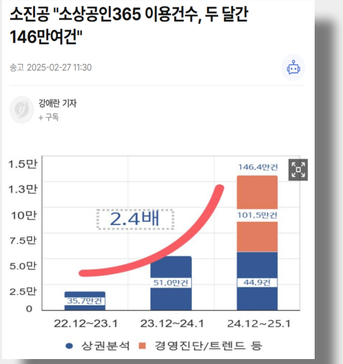

- **데이터 기반 의사결정의 중요성**이 높아지면서 소상공인시장진흥공단의 상권정보시스템인 '소상공인 365'의 이용건수가 **전년 대비 2배 이상 증가함**

상권, 업종 등 유형별 폐업 진단의 필요성

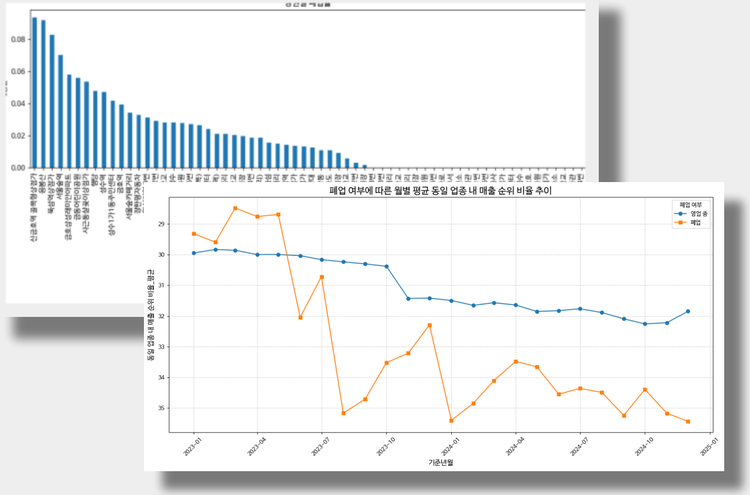

- 상권별 업종별 폐업률이 큰 차이를 보이며 **이외에도 유형별 요인을 고려한** 세분화된 폐업 분석이 필요함

데이터분석 로드맵

분석 배경 및 필요성 | **데이터 분석** | 모델링 | 아이디어 제안

"23~24년도 가맹점 데이터를 활용해 25년도 하반기 폐업을 예측하자!"

데이터 수집 및 전처리

- (기본 제공) 카드 데이터 신한카드
  - 데이터셋1 가맹점 개요정보
    big_data_set1_f.csv
  - 데이터셋2 가맹점 월별 이용 정보
    big_data_set2_f.csv
  - 제이터셋3 가맹점 고객
    big_data_set3_f.csv

- 외부 데이터 서울 열린데이터 광장
  - 상권 영역 정보
    서울시 상권분석서비스(영역-상권).shp
  - 상권별 유동인구
    서울시 상권분석서비스(길단위인구-상권).csv
  - 서울시 생활물가지수
    생활물가지수_20251005164822.csv

페업 예측 지표 설계

4가지 카테고리

상권
- 상권_활성화지수
- 상권_소비력
- 상권_집객력

가맹점 정보
- 유지기간_월
- 업종별 폐업률

가맹점 매출
- 동일 업종 매출금액 비율_변화율
- 물가 대비 민감도
- 소비자 구매력
- 최근 3개월 매출 평균

소비자 행동
- 남성 50대 고객 비중

모델링

모델링 진행

- SMOTE + Tomek Links
- StandardScaler
- Stratified K-Fold 교차검증
- 그리드 서치

모델링 성능

- F1 Score : 0.8955 (±0.0033)
- Recall : 0.9756 (±0.0020)
- Precision: 0.8276 (±0.0065)

인사이트 도출

K - means

- 폐업률·매출·고객 구성의 패턴을 탐색 위해 K-means 군집 분석 사용

분석 결과

- 유형별 인사이트
  - 지속 성장형
  - 안정 유지형
  - 경쟁력 약화형

[Preprocessing]

데이터 전처리

신한카드

분석 배경 및 필요성 | **데이터 분석** | 모델링 | 아이디어 제안

[제공 데이터셋1 가맹점 개요정보]	[제공 데이터셋2 가맹점 월별 이용 정보]	[제공 데이터셋3 가맹점 월별 이용 고객정보]

(공통)

- 컬럼명 → 한글컬럼명
- 기준년월을 datetime형으로 변환
- 가맹점 정보가 기록 7개월 이하인 데이터 제외 - 학습 품질을 떨어뜨리는 원인

- **"가맹점 주소" 표기 정규화**
  - 마침표 제거
  - "서울" → "서울특별시"로 통일
  - 성동구가 아닌 가맹점(2개) 제거
- **폐업여부 컬럼 추가**

- **구간을 의미하는 컬럼 수치형으로 변환**
  ex) "2_10%-25%"→ 2
- **"배달매출 금액 비율"**
  - **모든 컬럼이 결측** → 배달을 지원하지 않는 것으로 간주, 0으로 결측치 처리
  - **부분 결측** → 해당 가맹점의 평균으로 결측치 처리
- **"취소율 구간"**
  - **가맹점별 평균**으로 결측치 처리

- **결측치가 존재하는 모든 컬럼에 각 가맹점의 최빈값으로 결측치 대체**

전처리 전
- 가맹점 수: 4185개

→

전처리 후
- 가맹점 수: 4052개
- (가맹점 수)영업 : 폐업 = 3930 : 122

데이터 전처리

서울 열린데이터 광장

[외부데이터] 상권 영역 정보

- 서울시 상권 경계, 좌표 등의 공간 데이터
- **생활권 기반의 세분화된 상권 정보 포함 → 결측 상권 자동 보완 및 정교한 분석 가능**

• 상권 매핑

(1) 가맹점 주소 → 좌표 변환

(2) 좌표 → '서울 열린데이터' 상권 영역 매핑

1차 : '서울 열린데이터' 상권 기준으로 보정

2차 : 1차 처리 이후에도 결측인 가맹점은 '신한카드 데이터'의 상권으로 대체

1차 상권 매핑

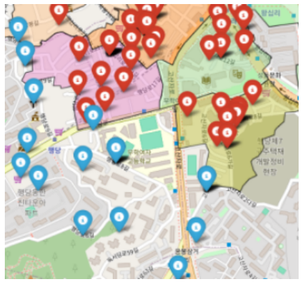

2차 상권 매핑

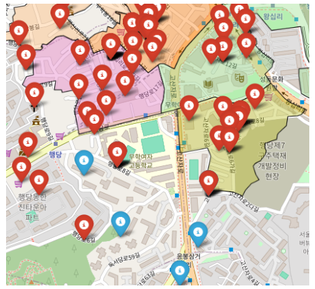

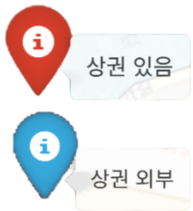

(3) 2차 처리 이후에도 상권 매핑이 안된 가맹점

: (상권 외 지역)으로 할당

• 결측치 처리 완료 및 세분화된 상권

상권 개수 : 12개 → 63개

상권	count
성수역	210
뚝섬역	176
왕십리도선동상점가	174
뚝섬	152
마장축산물시장	151
왕십리	142
성동용답상가시장	135
성원중학교	133
한양대앞상점가(한양시장, 왕십리맛골목)	130
경수초등학교	120
금남시장	116
한양대	111
성수초등학교	108

파생 변수 생성

신한카드 [제공 데이터셋1 가맹점 개요정보]

파생변수 1) 상권__소비력

- 상권 내 소비 수준을 나타냄
- 구간형 변수는 값이 작을수록 상위 구간을 의미하므로 지표 해석 통일을 위해 역변환(6-값)을 적용함
- 계산방법
  [{ (6 - 매출금액구간) ÷ 5 × 100 } +
  { (6 - 유니크고객수) ÷ 5 × 100 } +
  (100 - 동일업종내매출순위비율)] ÷3

서울 열린데이터 광장 [외부데이터]
상권별 유동인구 정보

- 서울시 주요 상권 및 분기별 길단위 유동인구 수
- **상권별 인구 밀집 확인 및 상권 활성화 수준 수치화 위해 사용**

	A	B	C
1	기준_년분기_코드	상권_코드_명	총_유동인구_수
2	20244	강남 마이스 관	105501
3	20244	잠실 관광특구	4181494
4	20244	종로?청계 관광	8476380
5	20244	동대문패션타운	3554720
6	20244	명동 남대문 북	7581802
7	20244	이태원 관광특구	2134393
8	20244	평화시장(남평호	60185
9	20244	고덕 골목형상점	102589
10	20244	명일전통시장	329425
11	20244	길동복조리시장	499142
12	20244	둔촌역전통시장	281328

파생변수 2) 상권__집객력

- 해당 상권에 얼마나 많은 사람이 방문하는지 나타냄
- 계산방법
  : 상권별 평균 유동인구 수 계산

파생변수 3) 상권_활성화지수

- 상권의 유입력과 소비력을 종합적으로 반영한 지수
- 계산방법
  1. 상권_집객력과 상권_구매력을 표준화
  2. 두 지표 간의 균형 수준을 반영하기 위해 기하평균으로 계산

파생 변수 생성

서울 열린데이터 광장

분석 배경 및 필요성 | **데이터 분석** | 모델링 | 아이디어 제안

[외부데이터] 서울시 생활물가지수

생활물가지수_20251005164822.csv

- 월별 생활필수품 가격 변동을 통해 측정한 물가 체감 지표
- 단순 매출 추이뿐 아니라 외부 경제 변수(물가)의 영향 반영

	A	B
1	시점	생활물가지수
2	2022. 12	110.23
3	2023. 01	111.32
4	2023. 02	111.94
5	2023. 03	112.15
6	2023. 04	112.27
7	2023. 05	112.94

파생변수 4) 물가 대비 민감도

- 물가 대비 민감도란?
  - 물가 변동이 매출에 미치는 영향 정도
  - 변동 방향보다 변화 폭에 집중하기 위해 절댓값 합계 사용

- 계산식
  - 물가변화율 : 월별 생활물가지수 변화율 [외부데이터 생활물가지수 활용]
  - 매출 변화율 : 가맹점별 매출 구간 변화량

물가 대비 민감도 = (매출 변화율)/(물가 변화율)의 절댓값 합

파생 변수 생성

신한카드

분석 배경 및 필요성 | **데이터 분석** | 모델링 | 아이디어 제안

[제공 데이터셋1 가맹점 개요정보]

[제공 데이터셋2 가맹점 월별 이용 정보]

[제공 데이터셋3 가맹점 월별 이용 고객정보]

파생변수 5) 소비자 구매력

- 가맹점 단위에서 소비자들의 평균 소비 수준
- 구간형 변수는 값이 작을수록 상위 구간을 의미하므로 지표 해석 방향을 통일하기 위해 역변환(6-값)을 적용함
- 계산식
  [{ (6 - 매출금액구간평균) ÷ 5 × 100) + (6 - 유니크고객수평균) ÷ 5 × 100) }] ÷ 2

파생변수 6) 업종별 폐업률

- 업종별 폐업률의 평균을 계산
- 업종별로 폐업률의 차이가 극심하므로 정량적 비교를 위해 설계함

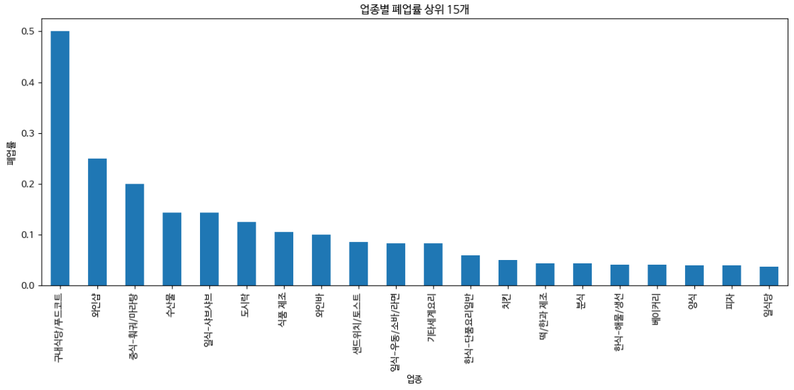

파생 변수 생성

신한카드

분석 배경 및 필요성 | **데이터 분석** | 모델링 | 아이디어 제안

[제공 데이터셋1 가맹점 개요정보]

파생변수 7) 유지기간_월

- 가맹점이 영업을 유지한 개월 수
- 계산방법
  폐업일 - 개설일

[제공 데이터셋2 가맹점 월별 이용 정보]

파생변수 8) 최근 3개월 매출 평균

- 최근 3개월 동안의 평균 매출 수준
- 계산방법
  최근 3개월의 매출금액구간 평균

파생변수 9)
동일 업종 매출금액 비율_변화율

- 동일 업종 내에서 각 가맹점의 매출 금액 비율이 이전 기간 대비 얼마나 변화했는지
- 계산방법
  전월 대비 동일 업종 매출 금액 비율 변화량 평균

[제공 데이터셋3 가맹점 월별 이용 고객정보]

파생변수 9) 남성 50대 고객 비중

- 남성 50대 고객의 비율
- 계산방법
  가맹점별 평균

변수 선택

VIF(분산 팽창 계수)

- VIF란?
  - 독립 변수 간의 다중공선성을 측정하는 지표
    VIF = 1 : 다른 변수와 상관관계가 없음
    VIF >= 5 : 다중공선성 주의
    VIF >= 10 : 심각한 다중공선성
- 다중공선성을 해결하기 위해 '상권_집객력','상권_소비력','소비자 구매력' 제거

(변수 제거 전)

	Feature	VIF
0	const	184.166291
1	상권_집객력	21.930574
2	상권_소비력	4.842996
3	상권_활성화지수	30.136370
4	물가 대비 민감도	1.034660
5	소비자 구매력	5.603220
6	업종별_폐업률	1.017416
7	유지기간_월	1.127262
8	최근 3개월 매출 평균	5.433598
9	동일 업종 매출금액 비율_변화율	1.164936
10	남성 50대 고객 비중	1.165734

(변수 제거 후)

	Feature	VIF
0	const	20.215267
1	상권_활성화지수	1.061640
2	물가 대비 민감도	1.031651
3	업종별_폐업률	1.015406
4	유지기간_월	1.117370
5	최근 3개월 매출 평균	1.138166
6	동일 업종 매출금액 비율_변화율	1.124789
7	남성 50대 고객 비중	1.096390

[최종 변수]

- 업종별_폐업률
- 유지기간_월
- 물가 대비 민감도
- 최근 3개월 매출 평균
- 남성 50대 고객 비중
- 동일 업종 매출금액 비율_변화율
- 상권_활성화지수

최종 데이터 셋

	가맹점구분번호	폐업여부	상권_활성화지수	물가 대비 민감도	업종별_폐업률	유지기간_월	최근 3개월 매출 평균	동일 업종 매출금액 비율_변화율	남성 50대 고객 비중
0	16184E93D9	False	1.268385	-20.930726	0.025641	149.4	3.333333	-1.704348	17.584146
1	4D039EA8B7	False	1.268385	12.717065	0.025641	141.3	2.666667	-4.147826	18.492058
2	0074C4990A	False	1.268385	55.003773	0.025641	135.7	2.0	-37.504348	11.831754
3	68308F2746	False	1.268385	26.734986	0.025641	117.2	4.666667	0.608696	7.111738
4	4117EDDE9C	False	1.268385	3.875	0.025641	116.7	5.666667	0.152174	0.000000
...	...	...	...	...	...	...	...	...	...
3836	7FCF23E6F3	False	0.964409	0.821269	0.000000	24.3	4.0	2.675000	5.173824
3837	9743B78531	False	0.964409	-9.955138	0.039216	149.9	1.333333	-0.156522	8.270196
3838	C2261977A8	False	0.910338	1.867732	0.025641	27.5	1.666667	8.552632	13.212625
3839	F1C69918DF	False	0.964409	4.591766	0.000000	46.8	3.333333	-1.286957	8.254367
3840	58B8C943BF	False	0.964409	-10.506828	0.000000	30.0	4.0	0.014286	5.820705

3841 rows × 9 columns

[Modeling]

모델링 진행과정

불균형 데이터 해결을 위한 샘플링

- SMOTE + Tomek Links
  - SMOTE
    : 소수 클래스 데이터 사이에서 새로운 가상 데이터를 생성해 불균형 해소
  - Tomek Links
    : SMOTE 후 경계에 있는 다수 클래스 샘플을 제거해 경계선 정제 및 성능 향상

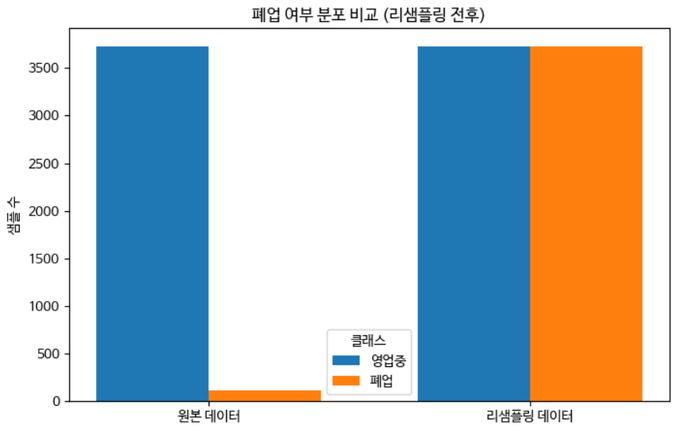

스케일링

- 표준화
  - StandardScaler
    ('상권_활성화지수'는 앞선 전처리 과정에서 표준화 된 값이므로 해당 컬럼은 제외)

모델링 진행과정

분류 모델 선정

	Model	Accuracy	Precision	Recall	F1
0	LogisticRegression	0.712871	0.703043	0.737074	0.719656
1	SVM	0.843234	0.798851	0.917492	0.854071
2	EasyEnsembleClassifier	0.804180	0.772414	0.862486	0.814969

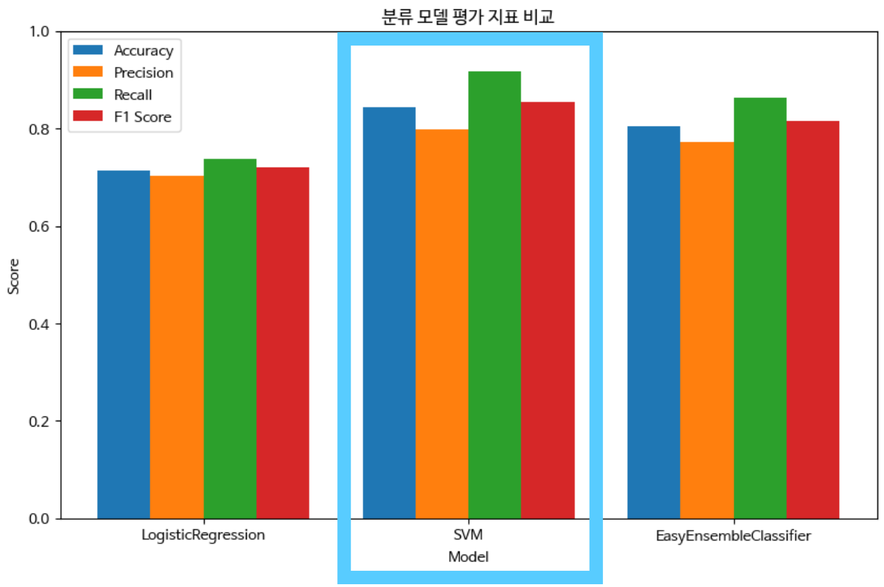

[Stratified K-Fold 교차검증]

- 성능

  Logistic Regression < EasyEnsembleClassifier < SVM

- 최종 선정 모델
  - SVM

    마진 최대화를 통해 복잡한 경계를 잘 분리함

    작은 데이터에도 강한 성능을 보이며 세 모델 중 평가 지표가 가장 높음

모델링 분석결과

하이퍼파라미터 튜닝

- 그리드 서치
  - {'C': 10, 'gamma': 'auto', 'kernel': 'rbf'}

변수 중요도

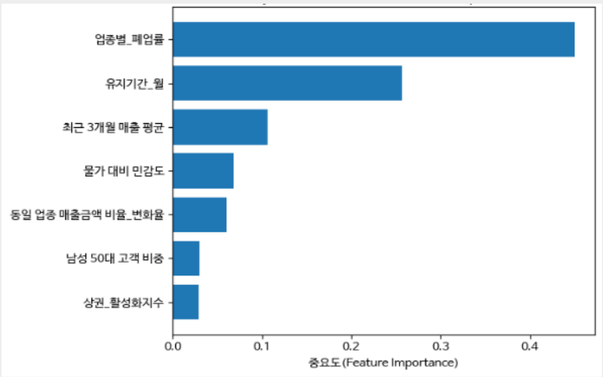

1. 업종별 폐업률
2. 유지기간_월
3. 최근 3개월 매출 평균
4. 물가 대비 민감도
5. 동일 업종 매출금액 비율_변화율
6. 남성 50대 고객 비중
7. 상권_활성화지수

최적 파라미터의 교차검증 성능

- F1 Score : 0.8955 (±0.0033)
- Recall : 0.9756 (±0.0020)
- Precision: 0.8276 (±0.0065)

모델링 분석결과

[K - means]

- 데이터 간 유사도 기반으로 자연스럽게 그룹을 찾기 위해 비지도학습 K-means 군집화 사용
- 군집 수 k=3으로 설정, 가맹점을 [경쟁력 약화형 / 안정 유지형 / 지속 성장형]으로 구분
- 최종 선택 변수와 동일

cluster	업종별_폐업률	유지기간_월	물가 대비 민감도	최근 3개월 매출 평균	남성 50대 고객 비중	동일 업종 매출금액 비율_변화율	상권_활성화지수
0	0.032	58.515	-3.854	2.242	7.094	7.702	2.922
1	0.024	178.141	-2.512	3.512	19.055	-0.785	1.905
2	0.032	54.625	-2.243	4.283	9.014	0.185	1.654

"상권은 활발하지만 매출 불안정성이 높은 가맹점"

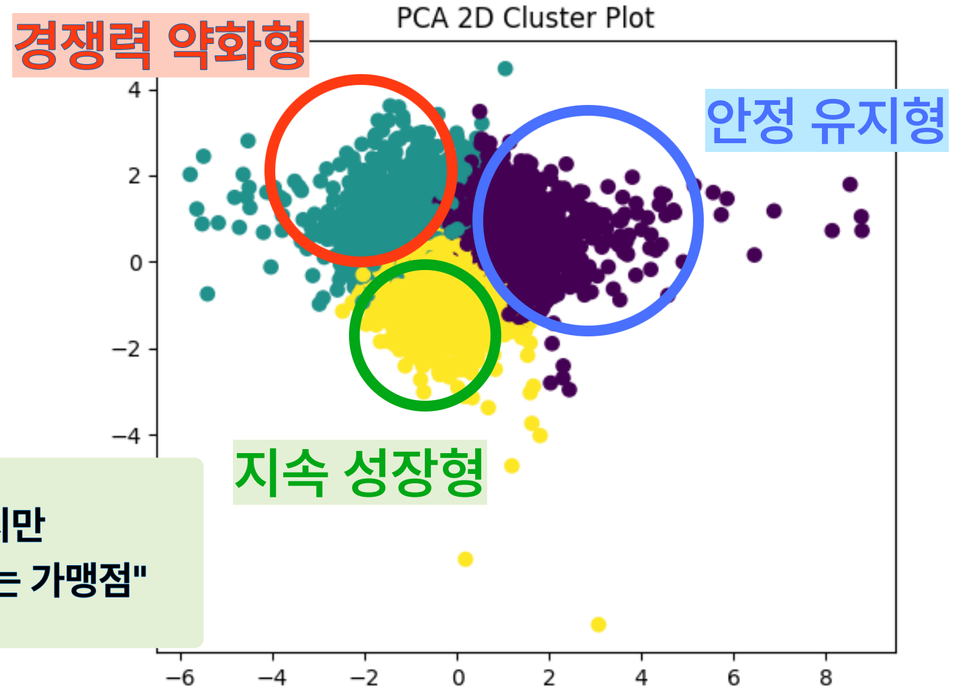

"장기 운영과 안정적 매출을 유지하는 가맹점"

"짧은 운영 기간이지만 성장세가 두드러지는 가맹점"

아이디어 제안

인사이트 도출

가맹점 유형	인사이트
경쟁력 약화형 ● 상권은 활발하지만 ● 매충 변동성이 높고 운영 기간이 짧음	○ 단기 이익보다 내부 경쟁력 강화 필요 ○ 폐업 위험도 높음
안정 유지형 ● 장기 운영 ● 폐업률이 낮고 50대 고객층 중심	○ 안정적 고객층 기반의 지속 가능한 매출 구조
지속 성장형 ● 매출 상승세 ● 점유율 증가	○ 투자 및 확장 가치가 높은 상권군

아이디어 제안

분석 배경 및 필요성 | 데이터 분석 | 모델링 | 아이디어 제안

활용방안

상권분석 웹페이지 - 소상공인을 위한 상권 분석 서비스 + 신한카드 금융 상품 연계

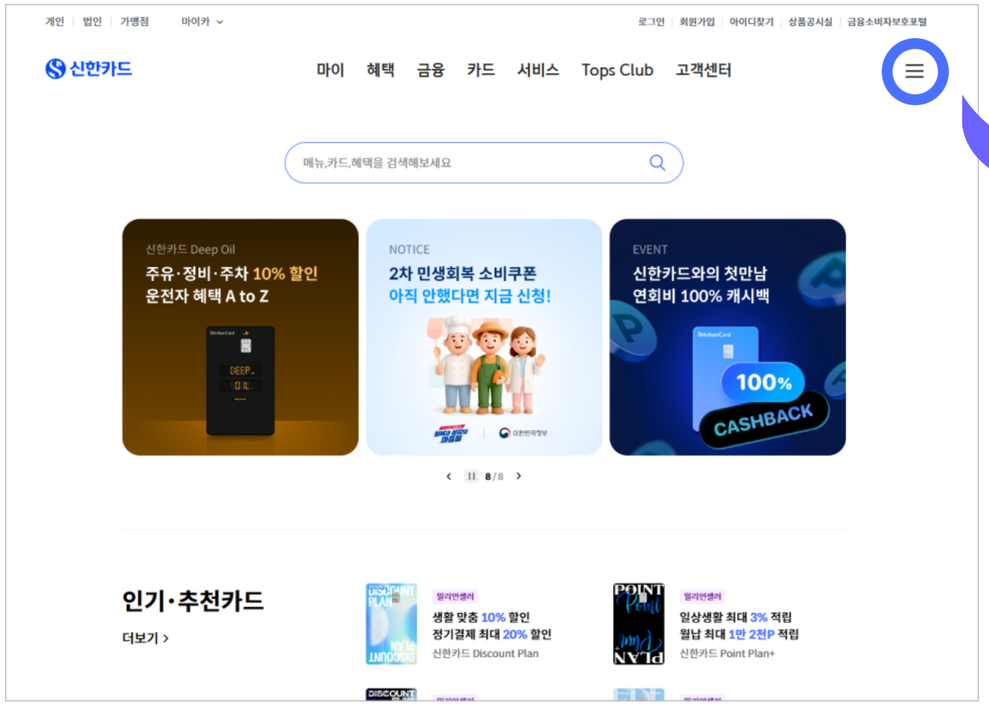

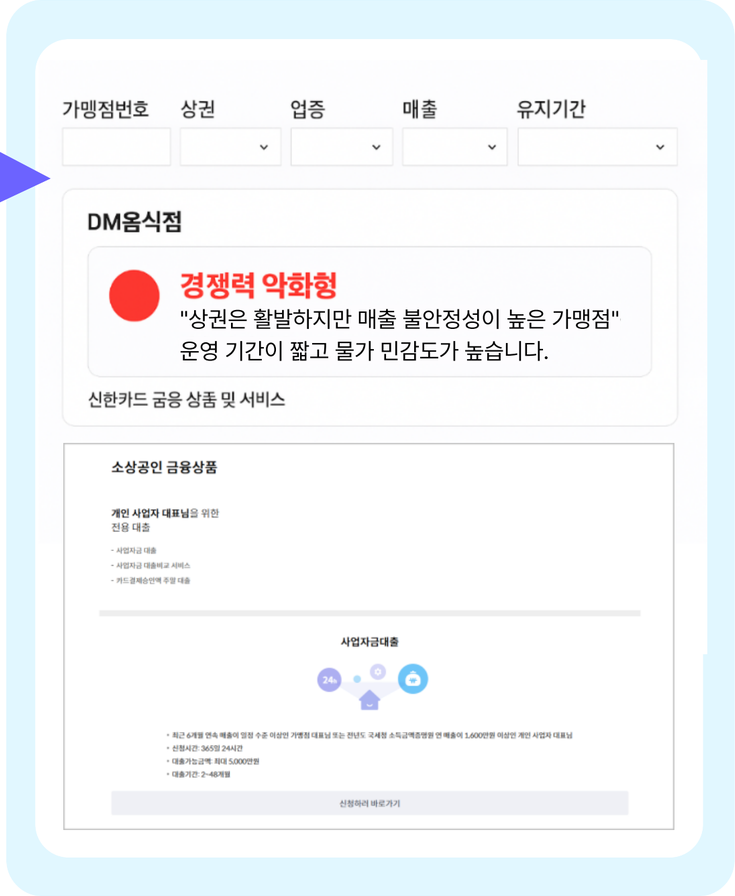

이미지 출처: 신한카드

- https://www.shinhancard.com/
- https://myshoppartner.shinhancard.com/conts/html/main.html